



Real-Time Social Media Sentiment Analysis

Pipeline Big Data temps réel:

Kafka

Spark

MongoDB

Streamlit

MOUTAOUAFFIQ Sidi Mohamed

SEKKAT Amine

LAMLOUM Ayoub

Pourquoi ce projet ?



Explosion des Données

Volume massif de messages générés chaque seconde sur les réseaux sociaux. L'analyse statique ne suffit plus.



Besoin Temps Réel

Nécessité de capter la tendance "maintenant". Réagir à l'instant T sur des sujets critiques (tech, politique).



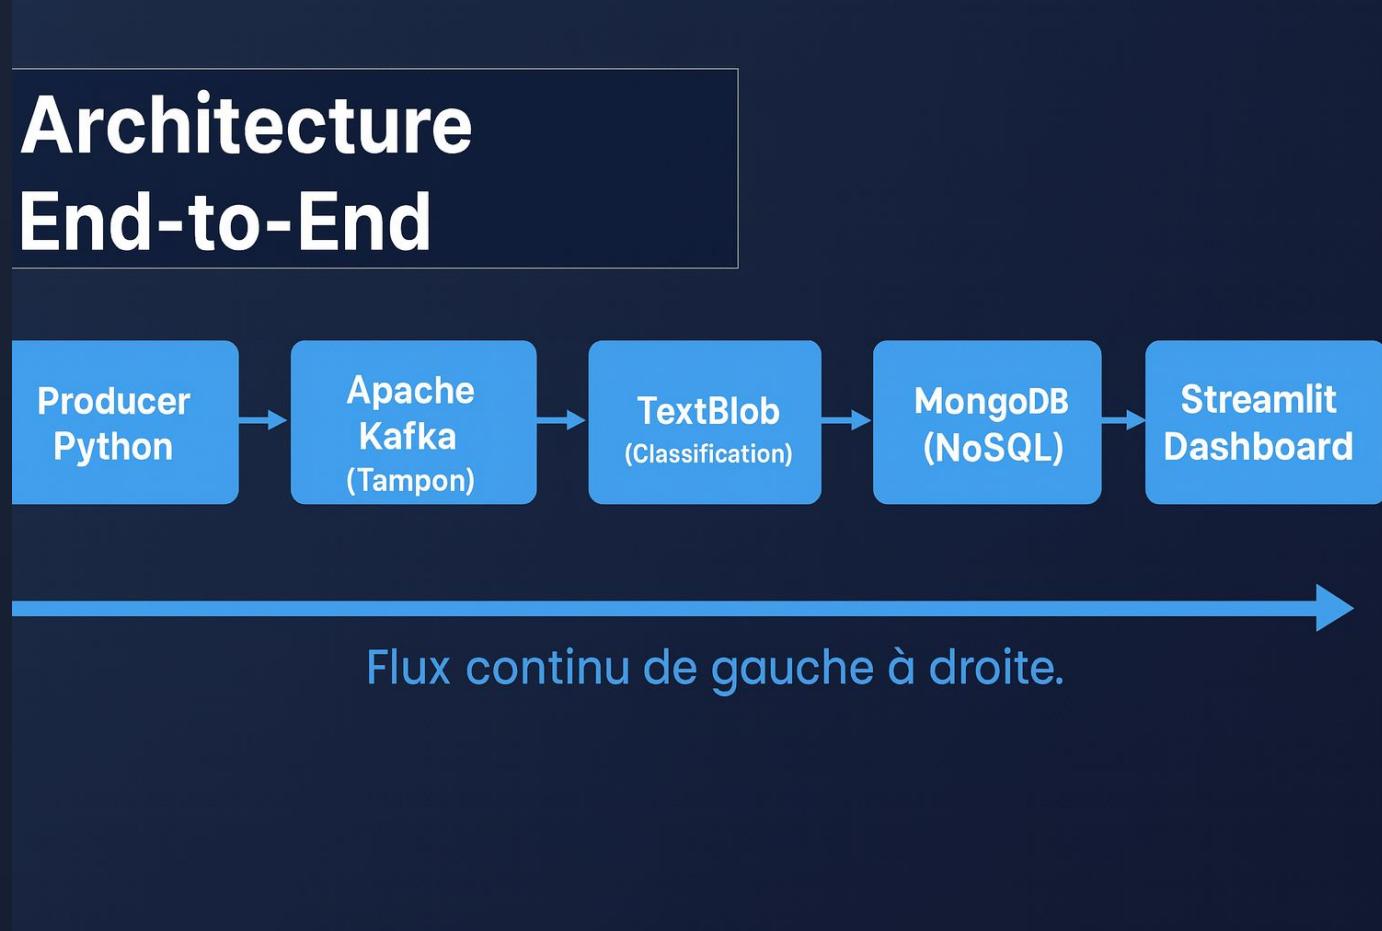
Défi Technique

Construire une chaîne Big Data complète : Ingestion, Streaming, NLP, Stockage et Visualisation.

Architecture End-to-End

- › **Source** : Producer Python (Simulation Faker)
- › **Broker** : Apache Kafka (Tampon)
- › **Processing** : Spark Structured Streaming
- › **NLP** : TextBlob (Classification)
- › **Storage** : MongoDB (NoSQL)
- › **Viz** : Streamlit Dashboard

Flux continu de gauche à droite.



1. Ingestion : Génération de Données

Le "Mock" Twitter

Simulation d'un flux API via un script Python.

- › Utilisation de la librairie **Faker**.
- › Format **JSON** structuré.
- › Topics variés : Tech, Politics, Sport, Music.
- › Débit : ~1 message/seconde vers le topic .

`twitter_stream`

```
1 import numpy as np
2 import matplotlib.pyplot as plt
3
4 # Function to generate Mandelbrot fractal
5 def mandelbrot(c, max_iter):
6     z = c
7     for n in range(max_iter):
8         if abs(z) > 2:
9             return n
10        z = z*z + c
11    return max_iter
12
13 # Image dimensions
14 width, height = 800, 800
15
16 # Display area parameters
17 re_min, re_max = -2.0, 1.0
18 im_min, im_max = -1.5, 1.5
19
20 # Maximum number of iterations
21 max_iter = 256
```



2. Messaging : Apache Kafka

Le système nerveux central de l'architecture.

- **Rôle :** Tampon haute performance pour découpler la production de la consommation.
- **Topic :** `twitter_stream`
- **Avantages :** Résilience aux pannes et scalabilité horizontale.
- Permet d'ajouter d'autres consommateurs futurs sans impacter la prod.

| 3. Processing : Spark & NLP

Spark Structured Streaming

Lecture du flux Kafka en temps réel et application du schéma JSON.

Logique NLP (UDF) :

```
if polarity > 0 → Positif  
if polarity < 0 → Négatif  
else → Neutre
```



4. Stockage : MongoDB



Base NoSQL Orientée Document

Flexibilité totale pour stocker les objets JSON enrichis.

DB:

twitter_db

Collection:

sentiments

Document : { texte, topic, timestamp, sentiment }

5. Visualisation : Dashboard

Indicateurs Temps Réel

Connexion directe à MongoDB avec Streamlit
(rafraîchissement auto).

- › Distribution des sentiments (Pie Chart)
- › Histogrammes par Topic
- › Heatmap : Sentiment vs Topic
- › Feed des derniers tweets

Analyse par Topic (Live Preview)



| Scénario de Démonstration

1

Infra

Docker Compose
(Kafka, Zookeeper, Mongo)

2

Spark

Lancement du processeur
`spark_processor.py`

3

Source

Génération des tweets
`producer.py`

4

Viz

Lancement Dashboard
`streamlit run app.py`



Challenges Techniques

Problèmes

Spark sur Windows : Erreurs Hadoop et winutils.exe manquants.

Type JSON : Le timestamp était mal interprété (String vs Double).

Latence Dashboard : Streamlit rechargeait toute la page à chaque update.

Solutions

Configuration stricte des variables d'env HADOOP_HOME.

Définition d'un schéma Spark StructType explicite.

Optimisation des requêtes Mongo et usage des caches Streamlit.

UX & Design du Dashboard

Objectif : Clarté

Passer de la donnée brute à l'information exploitable.

- **Aggrégation** : Préférence pour les % plutôt que les valeurs absolues.
- **Filtrage** : Vues dynamiques par Topic.
- **Storytelling** : Quel topic domine ? Quelle est l'humeur globale ?
- Palette de couleurs intuitive (Vert/Rouge).



Limites & Améliorations



Source de Données

Remplacer Faker par l'API officielle Twitter (X) ou Reddit pour des cas réels.



NLP Avancé

Remplacer TextBlob (basique) par des modèles Transformers (BERT, CamemBERT).



Industrialisation

Déploiement Cloud (AWS/Azure) et ajout de monitoring (Prometheus/Grafana).





Conclusio n

Réussite de la mise en place d'un pipeline **Big Data complet**.

Maîtrise de l'écosystème .

Kafka - Spark - Mongo

Merci de votre attention.